

Gerardito IA — Sistema de Orientación Vocacional

Presentado por:

Fátima del Carmen Ayala Santos – SMIS003321

Fernando Rubén Chévez Sánchez – SMIS890919

Meylin Nohely Reyes Medina – SMIS032721

Módulo 4: Desarrollo de Aplicaciones con IA

Semana 5: Observabilidad, Rendimiento y Escalabilidad.

Descripción del Servicio y Endpoint Crítico

Gerardito es un chatbot de orientación vocacional que usa Gemma 4 31B (Ollama Cloud) para generar diagnósticos personalizados. El endpoint seleccionado es POST /api/v1/diagnostico, que recibe habilidades e intereses del estudiante y devuelve una matriz de carrera con 3 sugerencias.

Flujo crítico: Request → Validación Pydantic → LLM (Ollama Cloud) → Parseo de respuesta → Guardado en PostgreSQL → Response.

Preguntas de Observabilidad y Campos Registrados

Pregunta de observabilidad	Campo registrado	Ejemplo
¿Qué solicitud se ejecutó?	endpoint, method	endpoint, method
¿Cuánto tardó?	tiempo_total_ms	1837.41 ms
¿Cuánto tardó el LLM?	tiempo_llm_ms	1834.36 ms
¿Fue exitosa?	status_code	200
¿Qué versión del modelo usó?	Log en consola	LLM [diagnostico] 1834ms
¿Qué error ocurrió?	status_code + log	500, 429, 422

```
{
  "endpoint": "/explorar",
  "method": "POST",
  "status_code": 200,
  "tiempo_total_ms": 1837.41,
  "tiempo_llm_ms": 1834.36,
  "created_at": "2026-08-22T03:19:57.616222+00:00"
},
```

Código de Instrumentación + Request Exitosa

```
app > middleware > observabilidad.py > ...
1  import time
2  import inspect
3  import logging
4  from starlette.middleware.base import BaseHTTPMiddleware
5  from starlette.requests import Request
6  from starlette.responses import Response
7
8  logger = logging.getLogger("observabilidad")
9
10 EXCLUDED_PATHS = {"/health", "/metadata", "/prueba-llm", "/docs", "/openapi.json"}
11
12
13 def timer_llm(nombre: str):
14     def decorator(func):
15         def wrapper(*args, **kwargs):
16             start = time.perf_counter()
17             result = func(*args, **kwargs)
18             elapsed = (time.perf_counter() - start) * 1000
19             logger.info(f"LLM [{nombre}] {elapsed:.0f}ms")
20             return result
21         async def async_wrapper(*args, **kwargs):
22             start = time.perf_counter()
23             result = await func(*args, **kwargs)
24             elapsed = (time.perf_counter() - start) * 1000
25             logger.info(f"LLM [{nombre}] {elapsed:.0f}ms")
26             return result
27         if inspect.iscoroutinefunction(func):
28             return async_wrapper
29         return wrapper
30     return decorator
31
32
33 class ObservabilidadMiddleware(BaseHTTPMiddleware):
34     async def dispatch(self, request: Request, call_next):
35         path = request.url.path
36         if any(path.endswith(p) for p in EXCLUDED_PATHS):
37             return await call_next(request)
38
39         body_bytes = 0
40         if request.method in ("POST", "PUT", "PATCH"):
41             try:
42                 raw = await request.body()
43                 body_bytes = len(raw)
44             except Exception:
45                 pass
46
47         start = time.perf_counter()
48
49         response = await call_next(request)
50         status_code = response.status_code
51
52         elapsed_total = (time.perf_counter() - start) * 1000
53         logger.info(
54             f"{request.method} {path} {status_code} {elapsed_total:.0f}ms"
55         )
56
57         return response
```

Code	Details
200	Response body <pre>{ "resultado_markdown": ";Hola! Qué perfil tan genial tienes. Contar con habilidades en programación y matemáticas, sumado a tu pasión por la tecnología y la ciencia, te pone en una posición privilegiada para triunfar en las carreras del futuro.\n\nAquí tienes mis recomendaciones basadas en tu perfil:\n\n Carrera Sugerida % de Afinidad Por qué encaja \n --- --- --- \n Ingeniería en Desarrollo de Software 100% Es la combinación perfecta entre tu habilidad de programación y tu interés en la tecnología. \n Ingeniería en Inteligencia de Negocios 95% Aprovecha tu capacidad matemática para analizar datos y generar soluciones tecnológicas estratégicas. \n Licenciatura o Profesorado en Matemáticas 80% Alinea directamente con tu dominio de las ciencias exactas y tu interés por la ciencia. \n\nTe invito a utilizar los botones para decidir tu futuro camino profesional." }</pre> Response headers <pre>access-control-allow-origin: * content-length: 914 content-type: application/json date: Sat, 22 Aug 2026 04:39:30 GMT server: uvicorn</pre>

Error Controlado

Error 422 (validación Pydantic):

Code	Details
422	Error: Unprocessable Content Response body <pre>{ "detail": [{ "type": "too_short", "loc": ["body", "habilidades"], "msg": "List should have at least 1 item after validation, not 0", "input": [], "ctx": { "field_type": "List", "min_length": 1, "actual_length": 0 } }, { "type": "too_short", "loc": ["body", "intereses"], "msg": "List should have at least 1 item after validation, not 0", "input": [], "ctx": { "field_type": "List", "min_length": 1, "actual_length": 0 } }] }</pre> Response headers

Error de texto basura:

Curl

```
curl -X 'POST' \
'http://127.0.0.1:8000/api/v1/validar-texto' \
-H 'accept: application/json' \
-H 'Content-Type: application/json' \
-d '{
  "texto": "askjdhfkajsdhf",
  "tipo": "habilidad"
}'
```

Request URL

```
http://127.0.0.1:8000/api/v1/validar-texto
```

Server response

Code

Details

200

Response body

```
{
  "es_valido": false,
  "mensaje_ui": "El texto ingresado no es válido para una habilidad. Por favor, ingresa datos reales ",
  "clasificacion": null
}
```

Download

Medición de Rendimiento

Se ejecutaron 138 solicitudes al endpoint POST /api/v1/diagnostico y otros endpoints del sistema. Ambiente: Oracle Cloud, Python 3.11, Gemma 4 31B via Ollama Cloud.

Herramienta: Swagger UI + script de testing, se obtuvieron los siguientes resultados:

Endpoint	Requests	p50 (ms)	p95 (ms)	Máx (ms)	Errores
/diagnostico	28	2,908	10,925	11,771	1
/explorar	12	2,181	6,809	6,809	0
/resena	13	867	6,418	6,418	3
/validar-texto	13	1,674	7,991	7,991	0
Global	138	1,443	6,418	11,771	18.12%

Métricas LLM:

Métrica	Valor
Promedio	2,918 ms
p50	2,148 ms
p95	7,991 ms
Máximo	11,769 ms
Mínimo	366 ms

```
"resumen": {
  "total_requests": 138,
  "tiempo_promedio_ms": 1952.07,
  "tiempo_max_ms": 11771.21,
  "tiempo_min_ms": 0.22,
  "p50_ms": 1443.97,
  "p95_ms": 6418.25,
  "tasa_error_pct": 18.12
}

"llm": {
  "promedio_ms": 2918.98,
  "max_ms": 11769.35,
  "min_ms": 366.88,
  "p50_ms": 2148.9,
  "p95_ms": 7991.07,
  "total_llm_ms": 189733.88
}
```

Cuello de Botella Identificado

Cuello de botella principal: La latencia del modelo LLM (Gemma 4 31B) es el factor dominante. El p95 de /diagnostico es de 10.9 segundos, donde ~8 segundos corresponden a la inferencia del modelo en Ollama Cloud.

Causa raíz: El modelo de 31B parámetros requiere tiempo significativo de procesamiento. No hay cache de resultados frecuentes.

Riesgo: Si Ollama Cloud tiene alta latencia o downtime, todo el sistema se degrada.

```
{
  "endpoint": "/diagnostico",
  "method": "POST",
  "status_code": 200,
  "tiempo_total_ms": 11771.21,
  "tiempo_llm_ms": 11769.35,
  "created_at": "2026-08-21T01:39:51.396700+00:00"
},
```

Mejora Aplicada

Mejora	Antes	Después
LLM sync vs async	invoke() bloqueaba el event loop → 500 en primera request	ainvoke() async → funciona correctamente
Rate limiting	Sin límite → abuso posible	slowapi: 5-10 req/min por endpoint
CORS	["*"] → cualquier sitio hacía requests	["https://gerarditoubg.qd.je"] en producción
Métricas	Sin p50/p95	Endpoint /metrics con percentiles
Docker	Container como root	Usuario appuser no-root

Plan de Escalabilidad

Resumen de docs/escalabilidad.md:

Nivel	Estrategia	Cuando	Impacto
Corto	Redis cache para diagnósticos similares	Si se repiten >30% las consultas	Reduce llamadas LLM ~30%
Corto	Rate limiting (ya implementado)	Ya activo	Protege contra abuso
Mediano	Workers async (Celery/RQ)	Si latencia p95 > 15s	Desacopla LLM del API
Mediano	Read replicas PostgreSQL	Si queries de metrics > 1000/día	Mejora rendimiento de lectura
Largo	Microservicios	Si el sistema crece 10x	Escalabilidad independiente