


MLOps

de modelos experimentales a sistemas de IA confiables

Basado en el documento de Google Cloud: “MLOps: canalizaciones de automatización y entrega continua en el aprendizaje automático”.



Fuente visual: Google Cloud Architecture Center, CC BY 4.0

CI · CD · CT · Monitoreo · Reentrenamiento


La idea central: el valor no está solo en entrenar un modelo, sino en operar todo el sistema de ML de forma continua.

¿Qué problema resuelve MLOps?

ML no falla solo por el algoritmo: falla por datos, despliegue, monitoreo y operación.

En un sistema real, el código de ML suele ser una parte pequeña. Lo complejo está alrededor:

Datos	recopilación, validación y preparación
Modelo	entrenamiento, evaluación y análisis
Operación	infraestructura, automatización y monitoreo
Gobierno	metadatos, linaje, reproducibilidad y versiones



MLOps organiza esta complejidad con prácticas de automatización, pruebas, entrega continua, reentrenamiento y monitoreo.

MLOps en una definición útil

Una práctica de ingeniería y cultura operacional para sistemas de aprendizaje automático.

MLOps = DevOps aplicado a ML, pero incorporando datos, modelos y reentrenamiento continuo.

CI

Integra cambios y prueba código, datos, esquemas y modelos.

CD

Entrega canalizaciones y servicios de predicción de forma confiable.

CT

Reentrena y valida modelos automáticamente con datos recientes.

Objetivo

Reducir fricción entre ciencia de datos, ingeniería y operación, para pasar de experimentos a producción sin perder control.

Principio práctico:
automatizar lo repetible y
monitorear lo que puede
cambiar.

DevOps vs. MLOps

MLOps conserva CI/CD, pero agrega dimensiones propias de ML.

Software tradicional


Código + dependencias + despliegue de una aplicación.

Pruebas unitarias e integración

Entrega paquete o servicio

Operación logs, uptime, errores

Cambio por cambios de código



ML en producción

Código + datos + modelos + métricas + drift + reentrenamiento.

datos, esquemas, entrenamiento y modelo

canalización + servicio de predicción

rendimiento predictivo, drift y sesgos

por código, datos nuevos o deterioro

Conclusión: en ML, “desplegar el modelo” no basta; se despliega una capacidad operacional completa.

Ciclo de vida de un modelo de ML

Ocho pasos que pueden ejecutarse manualmente o mediante una canalización automática.

01
Extracción de datos

02
Análisis de datos

03
Preparación

04
Entrenamiento

08
Supervisión

07
Entrega


06
Validación

05
Evaluación

El nivel de automatización determina la madurez de MLOps: desde notebooks y traspasos manuales hasta pipelines con CI/CD y monitoreo.

Nivel 0: proceso manual

El modelo se entrena y valida en notebooks o scripts; operación e ingeniería quedan separadas.



Características típicas


- Pasos manuales e interactivos
- Traspaso del modelo a ingeniería
- Iteraciones poco frecuentes
- Sin CI/CD formal
- Monitoreo limitado del rendimiento

Riesgo principal

El modelo puede perder exactitud en producción cuando cambian los datos o el entorno.

Nivel 1: automatización de la canalización de ML

El objetivo es entrenamiento continuo: usar datos recientes, validar y desplegar modelos con menor fricción.




Qué cambia

- Componentes reutilizables
- Validación automática de datos
- Validación automática de modelos
- Tienda de funciones
- Metadatos y linaje
- Activadores de reentrenamiento

Resultado: no solo se implementa un modelo; se implementa una canalización de entrenamiento que puede operar de forma recurrente.

Nivel 2: automatización CI/CD de la canalización

Ahora se automatiza también la compilación, prueba y despliegue de la canalización de ML.




Componentes clave

- Control de fuente
- Servicios de build y test
- Servicios de despliegue
- Registro de modelos
- Feature store
- Tienda de metadatos
- Orquestador de pipelines

Apto para equipos con muchas canalizaciones, cambios frecuentes y necesidad de trazabilidad operacional.

Etapas de una canalización MLOps automatizada

La automatización une desarrollo, entrenamiento, entrega del modelo y monitoreo en un ciclo.



Lectura ejecutiva

1. Experimentar
2. Versionar código
3. Integrar y probar
4. Desplegar pipeline
5. Entrenar con datos nuevos
6. Entregar modelo
7. Monitorear y retroalimentar

La supervisión se convierte en un gatillador de mejora continua, no solo en un tablero de alertas.

Ruta de adopción recomendada

No es necesario pasar del nivel 0 al nivel 2 de inmediato: se puede avanzar por capas.

1

Ordenar experimentos

versionado, datasets, métricas y artefactos

2

Automatizar validaciones

datos, esquemas, entrenamiento y modelo

3

Orquestar pipelines

ejecuciones reproducibles y trazables

4

Activar CT

reentrenamiento programado o por drift

5

Integrar CI/CD

build, test, despliegue y rollback controlado

Mensaje final

MLOps transforma ML en una capacidad empresarial repetible: modelos con evidencia, trazabilidad, automatización y monitoreo permanente.

Fuentes: Google Cloud Architecture Center, "MLOps: canalizaciones de automatización y entrega continua en el aprendizaje automático", última revisión 2024-08-28. Contenido e imágenes bajo CC BY 4.0 salvo indicación contraria.